

Template para entrega do projeto da disciplina
Ciência de Dados e Inteligência Artificial
Fase 2

Nome do
estudante


Nicolas Dorneles Seidler


Desenvolva um processo de ciência de dados no Orange Data Mining, cobrindo os elementos abaixo. **Para cada um dos itens solicitados é necessário inserir imagens que evidenciem o trabalho realizado.**

Exploração dos dados

Que tipo de experimentos você fez na exploração dos dados (verificação de outliers, cálculos de médias, dados inválidos etc.).

Durante a exploração, carregamos o dataset `cat_acidentes.csv` no Orange e visualizamos com Data Table, confirmando 67.065 linhas e 10 colunas, como data, ups, mortes, etc. Usamos Feature Statistics para visualizar estatísticas, mortes tinha média 0, desvio-padrão 18,76. Scatter Plot de ups e mortes mostrou pontos com mortes maior que 0 tendo ups alto maior que 10, sugerindo correlação. Pivot Table por região revelou que Sul possui o maior número de fatalidades, indicando área crítica. Verificamos outliers em feridos com valor máximo 34, fora do comum.





The screenshot shows the Orange Pivot Table widget. The 'Rows' field is set to 'regiao' (region). The 'Columns' field is set to '(Same as rows)'. The 'Values' field is set to 'mortes' (deaths). Under 'Aggregations', 'Sum' is selected. The 'Apply Automatically' checkbox is checked. The resulting pivot table is as follows:

		regiao				Total
		CENTRO	LESTE	NORTE	SUL	
regiao	CENTRO	23.0	0.0	0.0	0.0	23.0
	LESTE	0.0	52.0	0.0	0.0	52.0
	NORTE	0.0	0.0	61.0	0.0	61.0
	SUL	0.0	0.0	0.0	74.0	74.0
Total		23.0	52.0	61.0	74.0	210.0


Escolha de, ao menos, três algoritmos de aprendizado para a modelagem

Apresente os algoritmos utilizados e justifique a escolha.

Regressão Linear: Serve como ponto de partida para testar se variáveis como ups (correlacionada com mortes no **Scatter Plot**) têm impacto linear, útil para políticas simples como, por exemplo focar em acidentes com alta gravidade.

Random Forest: Aproveita os padrões geográficos (região) e tipos de acidentes (tipo_acid), oferecendo uma visão mais completa para intervenções específicas por região ou tipo de incidente.

Gradient Boosting: Foca em capturar os casos raros de mortes maior que 0, cruciais para salvar vidas, ajustando-se aos detalhes do dataset.



Gradient Boosting - Orange
✕

Name

Method

Basic Properties
 Number of trees:

 Learning rate:

☒ Replicable training

Growth Control
 Limit depth of individual trees:

 Do not split subsets smaller than:

Subsampling
 Fraction of training instances:

☒

☰ ? 📄 | ↔ - 📄 | -

Random Forest - Orange

×

Name

Random Forest

Basic Properties

Number of trees: 10

☐ Number of attributes considered at each split: 5

☐ Replicable training

☐ Balance class distribution


Growth Control

☐ Limit depth of individual trees: 3

☒ Do not split subsets smaller than: 5

☒ Apply Automatically

≡ ? 📄 | ➡ - ➡ 📄 | -



Preparação dos dados de acordo com as características dos algoritmos de aprendizado escolhidos

A preparação envolveu.

A preparação envolveu codificar variáveis categóricas como tipo_acid usando One-hot encoding para compatibilidade com regressão. Em seguida, utilizei o Select Rows para filtrar os dados de forma manual, selecionei 200 amostras com mortes > 0 e outras 200 com mortes = 0, totalizando 400 linhas equilibradas para análise. Essa abordagem foi adotada devido ao desbalanceamento natural do conjunto (muitos registros com zero mortes). Posteriormente, dividimos os dados em 80% treino e 20% teste utilizando o Data Sampler.

Continuize - Orange

Categorical Variables

★ **Preset: first as base**

Filter...

C

tipo_acid: one-hot

C

dia_sem: one-hot

C

noite_dia: one-hot

C

regiao: one-hot

C

cont_vit: one-hot

☐ Use preset

☐ Keep categorical

☐ First value as base

☐ Most frequent as base

☒ One-hot encoding

☐ Remove if more than 2 values

☐ Remove

☐ Treat as ordinal

☐ Treat as normalized ordinal

Numeric Variables

★ **Preset: no change**

Filter...

N

feridos

N

feridos_gr

N

ups

N

mortes: preset

Targets

☐ Use preset

☒ Keep as it is

☐ Standardize to $\mu=0, \sigma^2=1$

☐ Center to $\mu=0$

☐ Scale to $\sigma^2=1$

☐ Normalize to interval [-1, 1]

☐ Normalize to interval [0, 1]

Reset All

☒ Apply Automatically

≡ ? 📄

→ 67.1k ⇐ 67.1k

mortes > 0 - Orange

Conditions

N mortes

is greater than

0

x

Add Condition

Add All Variables

Remove All

☐ Remove unused values and constant features

☐ Remove unused classes

☒ Send Automatically

67.1k

200

66.9k

67.1k

mortes = 0 - Orange

Conditions

N mortes

equals

0

x

Add Condition

Add All Variables

Remove All

☐ Remove unused values and constant features

☐ Remove unused classes


☒ Send Automatically

67.1k

66.9k

200

67.1k



Execução dos experimentos de aprendizado e coleta das métricas

Descreva o processo e os resultados obtidos.

Executamos cada algoritmo no Test & Score, usando Cross-Validation (5 folds). Após preparar, coletamos as métricas MSE, RMSE, MAE, MAPE, R^2 .

- **Linear Regression:** MSE 0,024; RMSE 0,154; MAE 0,061; MAPE 64333581333584.602; R^2 0,919
- **Random Forest:** MSE 0,028; RMSE 0,168; MAE 0,050; MAPE 0,040; R^2 0,903
- **Gradient Boosting:** MSE 0,036; RMSE 0,190; MAE 0,059; MAPE 19871651241112.086; R^2 0,876

A Linear Regression foi o melhor modelo com base no RMSE (0,154) e R^2 (0,919), indicando menor erro e maior explicação da variância.

Test and Score - Orange

☒ Cross validation
Number of folds: 5
☒ Stratified
☐ Cross validation by feature
☐ Random sampling
Repeat train/test: 10
Training set size: 66 %
☐ Stratified
☐ Leave one out
☐ Test on train data
☐ Test on test data

Model	MSE	RMSE	MAE	MAPE	R2
Gradient Boosting	0.036	0.190	0.059	19871651241112.086	0.876
Random Forest	0.028	0.168	0.050	0.040	0.903
Linear Regression	0.024	0.154	0.061	64333581333584.602	0.919

Compare models by: Mean square error ☐ Negligible diff.: 0.1

	Gradient Boosting	Random Forest	Linear Regression
Gradient Boosting		0.732	0.805
Random Forest	0.268		0.964
Linear Regression	0.195	0.036	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Stratification is ignored for regression

Relato dos experimentos e lições aprendidas

Apresente uma reflexão acerca dos resultados obtidos com este projeto.

A Linear Regression superou modelos mais complexos (RMSE 0,154, R^2 0,919), ensinando que, neste dataset, relações lineares entre variáveis como ups e mortes (vista no **Scatter Plot**) podem ser mais predominantes do que o esperado. Isso sugere que os dados podem ter uma estrutura mais simples do que inicialmente assumido. Apesar de não ser o melhor em RMSE, o Random Forest teve o menor MAE (0,050) e um MAPE viável (0,040), indicando que é mais consistente em prever casos não nulos, o que ensina a importância de avaliar múltiplas métricas.

Os resultados mostram que a Linear Regression, com RMSE 0,154 e R^2 0,919, explica 91,9% da variância de mortes, sugerindo que variáveis como ups, feridos e região (codificadas) têm uma relação mais linear com mortes do que o esperado. O Random Forest (RMSE 0,168, R^2 0,903) e Gradient Boosting (RMSE 0,190, R^2 0,876) foram sólidos, mas menos eficazes, possivelmente devido a parâmetros padrão. O erro médio (RMSE 0,154) é pequeno em uma escala de 0 a 3, indicando previsões úteis, mas o R^2 alto não reflete totalmente a capacidade de prever casos raros, que são críticos para segurança viária. Isso faz refletir que, embora os modelos sejam eficazes em média, ajustes como reamostragem poderiam melhorar a detecção de fatalidades raras.

LINK PARA O ARQUIVO DO PROJETO DO ORANGE E DOS DADOS UTILIZADOS

Insira os links para os arquivos.

[cat_acidentes](#)

<https://d.docs.live.net/1da999c1d9e07cbc/Desktop/Ciencias%20de%20Dados%20-fase%201/Ciencias%20de%20Dados%20e%20Inteligencia%20Artificial%20-%20Fase%201%20Orange.ows>